

ĐẠI HỌC BÁCH KHOA HÀ NỘI
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG
— o0o —



BÁO CÁO PROJECT

Học phần: Project I

**Tên đề tài: Sử dụng ML cho bài toán
phân biệt cảm xúc văn bản**

Giáo viên hướng dẫn: Trần Đức Duy

Sinh viên thực hiện : Nguyễn Trịnh Minh Hiếu

MSSV : 20235078

Hà Nội - 2025

Mục lục

1	Giới thiệu bài toán	3
2	Chuẩn bị và tiền xử lý dữ liệu	4
2.1	Bộ dữ liệu - dataset	4
2.2	Tiền xử lý dữ liệu	4
2.3	Phân tích Khám phá Dữ liệu	5
2.4	Đặc trưng hoá dữ liệu, phân hoạch và xử lý mất cân bằng dữ liệu	6
2.4.1	Đặc trưng hóa dữ liệu	6
2.4.2	Xử lý mất cân bằng dữ liệu	7
3	Lý thuyết triển khai với các mô hình học máy	8
3.1	Một số mô hình học máy cơ bản	8
3.1.1	Linear Regression	8
3.1.2	Ridge Regression	8
3.1.3	SGD Regression	9
3.1.4	Support Vector Machine	10
3.1.5	Neural Network	10
3.2	Các thang đo đánh giá	12
3.2.1	MSE, RMSE, MAE	12
3.2.2	R^2_{score}	12
4	Thực nghiệm và đánh giá	13
4.1	Thực nghiệm	13
4.2	Đánh giá	13
4.2.1	Các kết quả thực nghiệm	13
4.2.2	Đánh giá	17
5	Kết luận	19

Chương 1

Giới thiệu bài toán

Phân biệt cảm xúc văn bản là một bài toán quan trọng, kinh điển và có tính ứng dụng rất cao trong lĩnh vực Xử lý ngôn ngữ tự nhiên (NLP) hay Học máy nói chung. Bài toán đặc biệt có ý nghĩa quan trọng trong thời đại ngày nay, khi môi trường internet mỗi ngày tạo ra vô vàn dữ liệu dạng văn bản, khiến cho việc phân loại tính chất về mặt sắc thái cảm xúc của văn bản trở nên cần thiết. Với project này, em lựa chọn bài toán cụ thể là phân biệt tính độc hại của các bình luận (như trên mạng xã hội) - bài toán toxic comment classification/detection.

Chương 2

Chuẩn bị và tiền xử lý dữ liệu

2.1 Bộ dữ liệu - dataset

Bộ dữ liệu em chọn cho bài toán là bộ dữ liệu tại [huggingface](#). Bộ dữ liệu có kích cỡ 478 MB, gồm 2,223,065 mẫu trong đó mỗi mẫu gồm các cột:

- `comment_text`: nguyên văn bình luận bằng tiếng Anh
- `non_toxic`: mức độ không độc hại của bình luận
- `toxic`: mức độ độc hại của bình luận
- `severe_toxic`: mức độ độc hại một cách nghiêm trọng của bình luận
- `obscene`: mức độ tục tĩu của bình luận
- `threat`: mức độ đe dọa của bình luận
- `insult`: mức độ xúc phạm của bình luận
- `identity_hate`: mức độ công kích cá nhân/nhóm người của bình luận

Các nhãn đều được biểu diễn bởi những giá trị số thực trong đoạn $[0, 1]$ để thể hiện mức độ. Do đó, trong trường hợp với dataset này, bài toán được quy về dạng bài toán **hồi quy với nhiều đầu ra/đầu ra nhiều chiều - Multi-Output Regression**.

2.2 Tiền xử lý dữ liệu

Với dữ liệu dạng văn bản (text), việc tiền xử lý là vô cùng quan trọng để đưa dữ liệu về dạng được chuẩn hóa, sẵn sàng cho việc mã hóa. Trong project này, em thực hiện tiền xử lý dữ liệu bằng những bước như sau:


- Chuẩn hóa: lowercase, bỏ số, bỏ ký tự đặc biệt / dấu câu, chỉ giữ lại chữ + khoảng trắng, bỏ khoảng trắng dư
- Tokenize: đưa dữ liệu văn bản thành các token đơn giản (1 token = 1 từ)
- Chuẩn hóa slang: các từ tiếng lóng, từ viết tắt,... được chuẩn hóa thành từ ngữ đầy đủ
- Loại bỏ stopwords: loại bỏ các từ chung chung không có nhiều ý nghĩa về mặt ngữ nghĩa từ thư viện `nltk` như "a", "an", "the",...


2.3 Phân tích Khám phá Dữ liệu

Phân tích Khám phá Dữ liệu (Exploratory Data Analysis - EDA) là một là một phương pháp quan trọng trong phân tích dữ liệu để hiểu rõ hơn về cấu trúc, xu hướng, mối quan hệ và các điểm bất thường trong tập dữ liệu. Trong project này, em thực hiện EDA đơn giản với các thao tác:

- Phân bố các nhãn (kiểm tra mức độ mất cân bằng).
- Độ dài trung bình của bình luận độc hại so với không độc hại.
- Trích xuất các từ/cụm từ phổ biến (Top N words/bigrams) cho mỗi nhóm nhãn.

Một số biểu đồ kết quả EDA như sau:





2.4 Đặc trưng hoá dữ liệu, phân hoạch và xử lý mất cân bằng dữ liệu

2.4.1 Đặc trưng hóa dữ liệu

Trong project này, em sử dụng TF-IDF để vector hóa dữ liệu. Đây là một phương pháp tương đối truyền thống trong NLP, với công thức

$$\text{tf-idf}(t, d) = \text{tf}(t, d) \times \text{idf}(t)$$

$$\text{tf}(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}}$$
$$\text{idf}(t) = \log \left(\frac{N}{\text{df}(t)} \right)$$

- t : thuật ngữ (term) đang xét.
- d : văn bản (document) chứa thuật ngữ t .
- $f_{t,d}$: số lần xuất hiện của thuật ngữ t trong văn bản d .
- $\text{tf}(t, d)$: tần suất xuất hiện của t trong d (term frequency).
- N : tổng số văn bản trong toàn bộ corpus.
- $\text{df}(t)$: số văn bản có chứa thuật ngữ t (document frequency).
- $\text{idf}(t)$: độ đo mức độ quan trọng của thuật ngữ dựa trên độ hiếm trong corpus (inverse document frequency).
- $\text{tf-idf}(t, d)$: trọng số TF-IDF biểu diễn mức độ quan trọng của thuật ngữ t trong văn bản d .

Số lượng feature trong `TfidfVectorizer` chính là kích thước của tập từ vựng (vocabulary). Ký hiệu là $|V|$, trong đó mỗi phần tử của V tương ứng với một thuật ngữ t trong công thức TF-IDF. Do đó, số feature chính là số giá trị mà biến t có thể nhận.

2.4.2 Xử lý mất cân bằng dữ liệu

Do tính chất mất cân bằng của bộ dữ liệu có sẵn (khoảng 70% số mẫu là `non_toxic`) và mục tiêu của bài toán là nhận diện các comment có tính `toxic`, em sử dụng `Class Weighting` để đảm bảo mô hình không bị thiên vị về phía đa số (`non_toxic`), cụ thể là giữ nguyên `weight = 1` với `non_toxic` và tăng `weight` cho các nhãn còn lại.

Em chia tập dữ liệu thành `train` và `test` với `test_size = 0.2`.

Chương 3

Lý thuyết triển khai với các mô hình học máy

3.1 Một số mô hình học máy cơ bản

3.1.1 Linear Regression

Linear Regression (hồi quy tuyến tính) là mô hình học máy dự đoán một giá trị liên tục bằng cách tìm mối quan hệ tuyến tính giữa các biến đầu vào (features) và biến đầu ra. Mục tiêu của mô hình là tìm bộ trọng số θ sao cho đường thẳng (hoặc siêu phẳng) ước lượng tốt nhất giữ cho sai số dự đoán nhỏ nhất theo tiêu chí MSE.

Công thức của mô hình:

Hàm dự đoán:

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n = \mathbf{x}^\top \boldsymbol{\theta}$$

Hàm mất mát (MSE):

$$J(\boldsymbol{\theta}) = \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2$$

Nghiệm đóng:

$$\boldsymbol{\theta} = (X^\top X)^{-1} X^\top \mathbf{y}$$

3.1.2 Ridge Regression

Ridge Regression là biến thể của Linear Regression, thêm điều kiện phạt (regularization) L2 lên các trọng số để giảm hiện tượng overfitting. Mục tiêu là tìm bộ tham số $\boldsymbol{\theta}$ sao cho sai số dự đoán và độ lớn của trọng số cùng được tối thiểu hóa.

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n = \mathbf{x}^\top \boldsymbol{\theta}$$

$$J(\boldsymbol{\theta}) = \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2$$

$$\boldsymbol{\theta} = (X^\top X + \lambda I)^{-1} X^\top \mathbf{y}$$

Trong đó:

- $\lambda \geq 0$ là hệ số điều chỉnh mức phạt L2.
- I là ma trận đơn vị kích thước $n \times n$.
- Khi $\lambda = 0$, Ridge Regression trở về Linear Regression chuẩn.

3.1.3 SGD Regression

SGD Regression (Stochastic Gradient Descent Regression) là phương pháp tối ưu trọng số $\boldsymbol{\theta}$ của mô hình hồi quy tuyến tính bằng thuật toán gradient descent trên từng mẫu dữ liệu (hoặc mini-batch). Phương pháp này đặc biệt hiệu quả với tập dữ liệu lớn.

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n = \mathbf{x}^\top \boldsymbol{\theta}$$

$$J(\boldsymbol{\theta}) = \frac{1}{2} (\hat{y}^{(i)} - y^{(i)})^2$$

Cập nhật trọng số theo Stochastic Gradient Descent:

$$\theta_j := \theta_j - \eta \frac{\partial J(\boldsymbol{\theta})}{\partial \theta_j} = \theta_j - \eta (\hat{y}^{(i)} - y^{(i)}) x_j^{(i)}$$

Trong đó:

- η là learning rate.
- i là chỉ số mẫu dữ liệu được chọn ngẫu nhiên.
- Khi áp dụng cho toàn bộ tập dữ liệu, phương pháp này tương đương Gradient Descent chuẩn.

3.1.4 Support Vector Machine

Support Vector Regression (SVR) là phương pháp hồi quy dựa trên khái niệm Support Vector Machine (SVM). Mục tiêu của SVR là tìm một hàm $\hat{y} = f(x)$ sao cho sai số dự đoán nằm trong một khoảng ε -margin, đồng thời vẫn duy trì độ phẳng của hàm hồi quy.

$$f(x) = \mathbf{w}^\top \phi(x) + b$$

với $\phi(x)$ là hàm ánh xạ dữ liệu gốc vào không gian đặc trưng (có thể phi tuyến), và b là bias.

$$\begin{aligned} & \text{minimize } \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m (\xi_i + \xi_i^*) \\ & \text{subject to: } \begin{cases} y_i - \mathbf{w}^\top \phi(x_i) - b \leq \varepsilon + \xi_i \\ \mathbf{w}^\top \phi(x_i) + b - y_i \leq \varepsilon + \xi_i^* \\ \xi_i, \xi_i^* \geq 0 \end{cases} \end{aligned}$$

Trong đó:

- ε là khoảng sai số cho phép (epsilon-insensitive tube).
- C là hệ số điều chỉnh trade-off giữa độ phẳng của hàm và sai số bên ngoài ε .
- ξ_i, ξ_i^* là slack variables biểu diễn sai số ngoài ε -tube.
- $\phi(x)$ là ánh xạ phi tuyến (kernel) để SVR có thể học quan hệ phi tuyến.

Ta giải bài toán tối ưu này bằng phương pháp nhân tử Lagrange với bài toán đối ngẫu. Trong bài toán này, em sử dụng kernel là **linear** để phù hợp với kích cỡ lớn của tập dữ liệu và tài nguyên máy tính trung bình.

3.1.5 Neural Network

Neural network (Mạng nơ-ron nhân tạo) là một mô hình học máy được thiết kế theo dạng mô phỏng cách các tế bào thần kinh bên trong não bộ con người truyền tín hiệu và xử lý thông tin. Về bản chất, mạng nơ-ron nhân tạo này là một mô hình toán học được triển khai dưới dạng thuật toán, giúp máy tính học từ dữ liệu và đưa ra dự đoán.

Multi-Layer Perceptron (MLP) là một loại Neural Network cơ bản, gồm nhiều lớp (layer) gồm các neuron kết nối đầy đủ (fully connected). Mục tiêu của MLP là học một ánh xạ phi tuyến từ đầu vào $\mathbf{x}$ sang đầu ra $\mathbf{y}$ thông qua các lớp ẩn (hidden layers) và các hàm kích hoạt (activation functions).

$$\mathbf{h}^{(1)} = \sigma(W^{(1)}\mathbf{x} + \mathbf{b}^{(1)})$$

$$\mathbf{h}^{(2)} = \sigma(W^{(2)}\mathbf{h}^{(1)} + \mathbf{b}^{(2)})$$

$$\hat{\mathbf{y}} = W^{(L)}\mathbf{h}^{(L-1)} + \mathbf{b}^{(L)}$$

Trong đó:

- $\mathbf{x}$: vector đầu vào.
- $\mathbf{h}^{(l)}$: vector đầu ra của lớp ẩn thứ l .
- $W^{(l)}, \mathbf{b}^{(l)}$: ma trận trọng số và vector bias của lớp l .
- $\sigma(\cdot)$: hàm kích hoạt phi tuyến (ReLU, sigmoid, tanh, ...).
- L : số lớp (layer) trong mạng.
- $\hat{\mathbf{y}}$: vector dự đoán đầu ra.

$$J(W, b) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}(\hat{\mathbf{y}}^{(i)}, \mathbf{y}^{(i)})$$

Trong đó $\mathcal{L}$ là hàm mất mát (loss function), ví dụ MSE cho hồi quy hoặc cross-entropy cho phân loại.

Quá trình học của MLP sử dụng thuật toán Backpropagation kết hợp với Gradient Descent. Mục tiêu là cập nhật các trọng số $W^{(l)}$ và bias $\mathbf{b}^{(l)}$ để giảm hàm mất mát $J(W, b)$.

$$W^{(l)} := W^{(l)} - \eta \frac{\partial J}{\partial W^{(l)}}, \quad \mathbf{b}^{(l)} := \mathbf{b}^{(l)} - \eta \frac{\partial J}{\partial \mathbf{b}^{(l)}}$$

Trong đó:

- η là learning rate.
- $\frac{\partial J}{\partial W^{(l)}}, \frac{\partial J}{\partial \mathbf{b}^{(l)}}$ được tính bằng thuật toán Backpropagation thông qua đạo hàm của hàm kích hoạt và lỗi từ lớp đầu ra ngược trở về.
- Quá trình này lặp đi lặp lại trên toàn bộ tập dữ liệu (epochs) cho đến khi hàm mất mát hội tụ.

3.2 Các thang đo đánh giá

3.2.1 MSE, RMSE, MAE

- **Mean Squared Error (MSE):**

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2$$

MSE đo trung bình bình phương sai số giữa giá trị dự đoán $\hat{y}^{(i)}$ và giá trị thật $y^{(i)}$. Giá trị lớn hơn phản ánh dự đoán kém chính xác.

- **Root Mean Squared Error (RMSE):**

$$\text{RMSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2} = \sqrt{\text{MSE}}$$

RMSE là căn bậc hai của MSE, đưa sai số về cùng đơn vị với biến đầu ra, dễ so sánh trực tiếp với giá trị thực.

- **Mean Absolute Error (MAE):**

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |\hat{y}^{(i)} - y^{(i)}|$$

MAE đo trung bình giá trị tuyệt đối sai số, nhạy với sai số lớn nhưng ít bị ảnh hưởng bởi outlier so với MSE.

3.2.2 R^2 score

Coefficient of Determination (R^2 score):

$$R^2 = 1 - \frac{\sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2}{\sum_{i=1}^m (y^{(i)} - \bar{y})^2}$$

Trong đó:

- $y^{(i)}$ là giá trị thật của mẫu thứ i .
- $\hat{y}^{(i)}$ là giá trị dự đoán của mẫu thứ i .
- $\bar{y} = \frac{1}{m} \sum_{i=1}^m y^{(i)}$ là giá trị trung bình của các giá trị thật.

R^2 đo tỷ lệ phương sai của dữ liệu đầu ra được mô hình giải thích.

- $R^2 = 1$: mô hình dự đoán hoàn hảo.
- $R^2 = 0$: mô hình không giải thích được biến động nào so với giá trị trung bình.
- $R^2 < 0$: mô hình kém hơn so với việc dự đoán bằng giá trị trung bình.

Chương 4

Thực nghiệm và đánh giá

4.1 Thực nghiệm

Em thực hiện thực nghiệm với các lớp mô hình `LinearRegression`, `SGDRegressor`, `Ridge`, `LinearSVR`, `MLPRegressor` thuộc thư viện học máy cơ bản `sklearn`, với phân chia trọng số `sample_weight` như đã trình bày ở mục 2.4.2.

Các tham số cho từng mô hình hầu hết sử dụng tham số mặc định của thư viện, với một số ít thay đổi:


- SVM: `max_iter=5000` để phù hợp với tài nguyên máy tính (training khoảng 3 tiếng) và đủ để hội tụ
- MLP:
 - `hidden_layer_sizes=(256, 128)`,
 - `activation='relu'`,
 - `solver='adam'`,
 - `batch_size=256`,
 - `early_stopping=True`


Đặc biệt, với MLP, do giới hạn tài nguyên máy tính, em thực hiện lấy subset nhỏ gồm 50000 mẫu trong tập dữ liệu gốc với nguyên tắc **stratified sampling** để giữ nguyên tỉ lệ mẫu toxic như tập dữ liệu gốc.

4.2 Đánh giá

4.2.1 Các kết quả thực nghiệm

So sánh các model theo từng metric





So sánh từng metric của từng label trên mỗi model

Sử dụng ML cho bài toán phân biệt cảm xúc văn bản

Linear Regression Performance Metrics

Label	MSE	MAE	RMSE	R2
non_toxic	0.1481	0.3155	0.3849	0.2784
toxic	0.0233	0.1020	0.1528	0.4633
severe_toxic	0.0011	0.0090	0.0336	0.1663
insult	0.0049	0.0242	0.0700	0.4628
obscene	0.0020	0.0153	0.0449	0.1825
identity_hate	0.0174	0.0820	0.1319	0.4677
threat	0.0043	0.0285	0.0653	0.3333
Average	0.0287	0.0824	0.1262	0.3363

Ridge Regression Performance Metrics

Label	MSE	MAE	RMSE	R2
non_toxic	0.1481	0.3157	0.3849	0.2784
toxic	0.0233	0.1020	0.1528	0.4633
severe_toxic	0.0011	0.0090	0.0336	0.1663
insult	0.0049	0.0242	0.0700	0.4628
obscene	0.0020	0.0153	0.0449	0.1827
identity_hate	0.0174	0.0821	0.1319	0.4677
threat	0.0043	0.0285	0.0653	0.3334
Average	0.0287	0.0824	0.1262	0.3364

SGD Regression Performance Metrics

Label	MSE	MAE	RMSE	R2
non_toxic	0.1557	0.3436	0.3945	0.2417
toxic	0.0259	0.1166	0.1610	0.4039
severe_toxic	0.0011	0.0094	0.0338	0.1522
insult	0.0054	0.0287	0.0736	0.4050
obscene	0.0020	0.0158	0.0452	0.1729
identity_hate	0.0194	0.0954	0.1393	0.4065
threat	0.0044	0.0311	0.0666	0.3067
Average	0.0306	0.0915	0.1306	0.2984

SVM Performance Metrics

Label	MSE	MAE	RMSE	R2
non_toxic	0.1767	0.2334	0.4203	0.1392
toxic	0.0255	0.0774	0.1598	0.4132
severe_toxic	0.0014	0.0050	0.0370	-0.0116
insult	0.0051	0.0143	0.0711	0.4455
obscene	0.0023	0.0086	0.0478	0.0736
identity_hate	0.0193	0.0607	0.1388	0.4111
threat	0.0049	0.0196	0.0698	0.2386
Average	0.0336	0.0598	0.1349	0.2442

MLP Performance Metrics

Label	MSE	MAE	RMSE	R2
non_toxic	0.1631	0.3309	0.4038	0.2069
toxic	0.0286	0.1005	0.1691	0.3346
severe_toxic	0.0012	0.0072	0.0340	-0.1592
insult	0.0065	0.0281	0.0809	0.2538
obscene	0.0025	0.0198	0.0501	0.1015
identity_hate	0.0220	0.0850	0.1484	0.3244
threat	0.0044	0.0321	0.0666	0.2695
Average	0.0326	0.0862	0.1361	0.1902

4.2.2 Đánh giá

Dựa vào các kết quả thu được, ta có những nhận xét cùng lý giải sau:

- Các model đều hoạt động ở mức ổn, đạt MAE, MSE và RMSE ổn so với một mô hình xử lý ngôn ngữ.
- Điểm R^2 của các mô hình từ khoảng 0.2 đến 0.35, khoảng giá trị tuy xét với bài toán hồi quy nói chung là chưa ổn, nhưng hoàn toàn chấp nhận được đối với bài toán xử lý ngôn ngữ - vốn là một dạng dữ liệu nhiều noise, quá đa dạng về mặt ngữ cảnh và ngữ nghĩa và được vector hóa bằng TF-IDF tạo nên dữ liệu train có tính chất thưa.
- SVM đạt kết quả tốt hơn hẳn với MAE còn các chỉ số khác thì không, có thể lý giải được do bản chất tối ưu của SVM là phạt tuyến tính đối với lỗi nên gần với MAE hơn
- Linear Regression và các biến thể (Ridge, SGD) hoạt động tốt hơn những mô hình phức tạp hơn là SVM và MLP. Điều này có thể lý giải được do: cách vector hóa dữ liệu là TF-IDF với 5000 features, trong khi mỗi mẫu comment chỉ có vài đến vài chục từ, dẫn đến dữ liệu train rất thưa - so với mô hình SVM cơ bản hay MLP cơ bản thì mô hình tuyến tính là thích hợp hơn.
- Các nhãn như `toxic`, `insult`, `identity_hate` có phần "dễ đoán" hơn các nhãn còn lại với điểm R^2 còn `severe_toxic` hay `obscene` có các chỉ số MSE, MAE hay RMSE thấp hơn. Điều này là hoàn toàn hợp lý do đặc trưng của các từ ngữ `toxic` hay `insult` có phổ rộng, đa dạng nên phương sai cao hơn và lượng mẫu positive không quá lệch, còn với `obscene` và `severe_toxic` có phần rất lớn số mẫu bằng 0 nên mô hình chỉ cần đoán gần 0 là sẽ đạt MSE cao còn R^2 thấp do phương sai cao. Điều này cũng không có nghĩa là mô hình hoàn động không tốt mà chỉ là đặc trưng của nhóm dữ liệu.

Tuy kết quả thu nhận được là ổn, song trong tương lai ta vẫn có thể cải tiến theo nhiều cách như sử dụng nền tảng/máy tính có tài nguyên tốt hơn, tinh chỉnh một số siêu tham

số của các mô hình phức tạp, hay sử dụng các kiến trúc phức tạp hơn, hiệu quả hơn về mặt ngữ nghĩa như LSTM, BERT,...

Chương 5

Kết luận

Như vậy, ta đã giải quyết bài toán phân biệt cảm xúc văn bản, cụ thể là xác định tính độc hại của bình luận, bằng một số phương pháp học máy và học sâu cơ bản. Các kết quả thực nghiệm thu được tương đối ổn định với các lý giải hợp lý về mặt lý thuyết, song vẫn cần cải thiện hơn nữa trong tương lai với các kỹ thuật phức tạp hơn để mang lại hiệu quả State-of-the-Art.